

Mohamed Amine Merzouk

CHERCHEUR POSTDOCTORAL · MILA ET UNIVERSITÉ MCGILL

✉ mohamed-amine.merzouk@mila.quebec | 🏠 mamerzouk.github.io | 💻 github.com/mamerzouk | 🔗 linkedin.com/in/mamerzouk | 🎓 Google Scholar

BIOGRAPHIE

Chercheur en sécurité de l'IA, je travaille sur l'alignement des grands modèles de langage. Je suis chercheur postdoctoral à l'Université McGill et à Mila avec le Pr. Adam Oberman, où j'étudie des méthodes d'alignement qui agissent sur les représentations internes des modèles, ce que les modèles de langage encodent à propos de leur propre état et de leurs sorties, ainsi que l'honnêteté et la tromperie. Je viens de la cybersécurité : ma thèse de doctorat à Polytechnique Montréal, codirigée par le Pr. Frédéric Cuppens et Reda Yaich (IRT SystemX), portait sur les attaques adverses et les défenses pour la détection d'intrusion réseau fondée sur l'apprentissage automatique, et a été nommée pour le prix de la meilleure thèse.

ÉDUCATION

Philosophiæ doctor (PhD) en Génie Informatique

Polytechnique Montréal

Montréal, Canada

Janvier 2021 - Septembre 2024

Thèse : *A Landscape of Adversarial Threats to Machine Learning-Based Intrusion Detection*, nommée pour le prix de la meilleure thèse. Direction : Pr. Frédéric Cuppens (Polytechnique Montréal) et Reda Yaich (IRT SystemX).

Master en Informatique

École Nationale Supérieure d'Informatique (ESI ex.INI)

Alger, Algérie

Septembre 2018 - Septembre 2020

Mémoire : *Adversarial Machine Learning against Anomaly-based Intrusion Detection Systems*. Direction : Pr. Lydia Bouzar.

Ingénieur d'État en Informatique

École Nationale Supérieure d'Informatique (ESI ex.INI)

Alger, Algérie

Septembre 2017 - Septembre 2020

Classe préparatoire en Mathématiques et Informatique

École supérieure en informatique 08 Mai 1945

Sidi Bel Abbès, Algérie

Septembre 2015 - Septembre 2017

EXPÉRIENCE PROFESSIONNELLE

Chercheur postdoctoral

Université McGill et Mila - Institut Québécois d'Intelligence Artificielle

Montréal, Canada

Octobre 2024 - Présentement

Sécurité de l'IA et alignement des grands modèles de langage, avec le Pr. Adam Oberman.

Chargé de cours

Polytechnique Montréal

Montréal, Canada

Janvier 2021 - Août 2026

Cours de cybersécurité au premier cycle et aux cycles supérieurs.

Chercheur doctoral

IRT SystemX

Montréal, Canada

Janvier 2021 - Septembre 2024

Recherche doctorale sur l'apprentissage automatique adverse pour la détection d'intrusion réseau.

Chercheur stagiaire

IMT Atlantique

Rennes, France

Mars 2020 - Septembre 2020

Stage de recherche ayant mené à l'article *A Deeper Analysis of Adversarial Examples in Intrusion Detection* (CRiSIS 2020).

Auditeur stagiaire en cybersécurité

KPMG

Alger, Algérie

Juillet 2019 - Août 2019

Mise en œuvre de la norme ISO 27001 de gestion de la sécurité de l'information : analyse des risques et rédaction de politiques et de mesures de sécurité.

Ingénieur stagiaire en virtualisation et infonuagique

ADEX Technology

Alger, Algérie

Juin 2018 - Novembre 2018

Conception et déploiement d'une infrastructure infonuagique privée Red Hat OpenStack : architecture des services de calcul et sécurisation de la plateforme.

Technicien de support en TI

British Petroleum

Soutien aux utilisateurs et maintenance des postes de travail : dépannage, installation de logiciels et gestion des comptes.

Alger, Algérie

Septembre 2018 - Octobre 2018

Développeur logiciel stagiaire

EGC 1988

Développement d'un progiciel de gestion intégré (ERP).

Alger, Algérie

Juillet 2017 - Octobre 2017

EXPÉRIENCE D'ENSEIGNEMENT À POLYTECHNIQUE MONTRÉAL

- INF8102** **Sécurité dans les environnements infonuagiques.** Chargé de cours : Automne 2025.
- INF8085** **Cybersécurité.** Chargé de cours : Été 2025, Hiver 2026, Été 2026.
- CR345** **Sécurité des serveurs.** Chargé de cours : Hiver 2025.
- INF4420** **Sécurité informatique.** Chargé de cours : Été 2023, Été 2024. Chargé de laboratoire : Hiver 2022, Automne 2022, Été 2023, Été 2024.
- INF6103** **Cybersécurité des infrastructures critiques.** Chargé de laboratoire : Hiver 2022, Automne 2022, Automne 2023, Automne 2024.
- INF8602** **Sécurité des systèmes d'exploitation.** Chargé de laboratoire : Hiver 2022.
- INF1040** **Introduction à l'ingénierie informatique.** Correcteur : Hiver 2021, Automne 2021.

PUBLICATIONS

ARTICLES DE REVUE

Efficiency vs. Alignment: Investigating Safety and Fairness Risks in Parameter-Efficient Fine-Tuning of LLMs

Mina Taraghi, Yann Pequignot, Amin Nikanjam, Mohamed Amine Merzouk, Foutse Khomh

IEEE Transactions on Artificial Intelligence (2026). 2026

Adversarial robustness of deep reinforcement learning-based intrusion detection

Mohamed Amine Merzouk, Christopher Neal, Joséphine Delas, Reda Yaich, Nora Boulahia-Cuppens, Frédéric Cuppens

International Journal of Information Security (2024). Springer, 2024

Investigating the practicality of adversarial evasion attacks on network intrusion detection

Mohamed Amine Merzouk, Frédéric Cuppens, Nora Boulahia-Cuppens, Reda Yaich

Annals of Telecommunications 77.11 (2022) pp. 763–775. Springer, 2022

ARTICLES DE CONFÉRENCE

How Much is Left? LLMs Linearly Encode Their Remaining Output Length

Mohamed Amine Merzouk, Dmitri Carpov, Mirko Bronzi, Damiano Fornasieri, Adam Oberman

Advances in Neural Information Processing Systems (NeurIPS), 2026

Efficient Safety Alignment of Language Models via Latent Personality Traits

Mohamed Amine Merzouk, Nolan Smyth, Damiano Fornasieri, Linh Le, David Williams-King, Adam Oberman

Conference on Language Modeling (COLM), 2026

Latent Personality Alignment: Improving Harmlessness Without Mentioning Harms

Linh Le, David Williams-King, Mohamed Amine Merzouk, Aton Kamanda, Adam Oberman

Trustworthy AI Workshop, International Conference on Learning Representations (ICLR), 2026

Diffusion-based Adversarial Purification for Intrusion Detection

Mohamed Amine Merzouk, Erwan Beurier, Reda Yaich, Nora Boulahia-Cuppens, Frédéric Cuppens, Foutse Khomh

Proceedings of the 39th Annual IFIP WG 11.3 Conference on Data and Applications Security and Privacy (DBSec), 2025

Parameterizing poisoning attacks in federated learning-based intrusion detection

Mohamed Amine Merzouk, Frédéric Cuppens, Nora Boulahia-Cuppens, Reda Yaich

Proceedings of the 18th International Conference on Availability, Reliability and Security (ARES), 2023

Evading Deep Reinforcement Learning-based Network Intrusion Detection with Adversarial Attacks

Mohamed Amine Merzouk, Joséphine Delas, Christopher Neal, Frédéric Cuppens, Nora Boulahia-Cuppens, Reda Yaich

Proceedings of the 17th International Conference on Availability, Reliability and Security (ARES), 2022

A Deeper Analysis of Adversarial Examples in Intrusion Detection

Mohamed Amine Merzouk, Frédéric Cuppens, Nora Boulahia-Cuppens, Reda Yaich

Proceedings of the 15th International Conference on Risks and Security of Internet and Systems (CRISIS), 2021

PRÉPUBLICATIONS

Quantifying Overclaiming Propensity in Frontier LLM Agents

Nolan Smyth, Yorguin-Jose Mantilla-Ramos, Pascal Jr Tikeng Notsawo, Saskia Helbling, Alberto Tosato, Mohamed Amine Merzouk, Nouha Dziri, Gauthier Gidel, Tommaso Tosato

Preprint, arXiv:2609.20812, 2026

Deep-Cover Agents: Long-Horizon Prompt Injections on Production LLM Systems

Neel Alex, Mohamed Amine Merzouk, David Krueger

Preprint, 2026

THÈSES ET MÉMOIRES

A Landscape of Adversarial Threats to Machine Learning-Based Intrusion Detection

Mohamed Amine Merzouk

Ph.D. Thesis. Polytechnique Montréal, 2024

Adversarial Machine Learning against Anomaly-based Intrusion Detection Systems

Mohamed Amine Merzouk

M.Sc. Thesis. École Nationale Supérieure d'Informatique (ESI ex. INI), 2020

PRIX ET FINANCEMENT

2025	Subvention AI Safety Catalyst (avec les Pr. Khomh, Ma et Goebel) , Canadian AI Safety Institute & CIFAR	Montréal, Canada
2024	Nomination pour le prix de la meilleure thèse , Polytechnique Montréal	Montréal, Canada
2023	Prix de la meilleure présentation , InCyber International Forum	Montréal, Canada
2021	Bourse Mitacs Accélération Internationale pour la recherche doctorale , Polytechnique Montréal	Montréal, Canada
2014	1ère place aux Olympiades régionales de mathématiques , ASA Science	Alger, Algérie

CONFÉRENCES

2025	IRT SystemX , Purification adverse par diffusion pour la détection d'intrusion	Paris, France
2023	InCyber International Forum , L'IA de confiance (Prix de la meilleure présentation)	Montréal, Canada
2023	BSides Algiers , Menaces adverses pendant l'entraînement et l'inférence	Alger, Algérie
2023	Cyberconference (Cybereco) , Table ronde sur la sécurité de l'IA	Montréal, Canada
2022	School of AI Summit , Empoisonnement adverses en apprentissage fédéré	Alger, Algérie
2022	International Cybersecurity Forum , Masterclass en apprentissage adverse	Montréal, Canada
2022	Canadian AI Federated Learning Workshop , La menace des clients malveillants en apprentissage fédéré	Toronto, Canada
2022	Mila - Institut Québécois d'Intelligence Artificielle , Génération d'exemples adverses avec contraintes	Montréal, Canada
2021	Lancement de la chaire CRITiCAL , Attaques adverses contre les systèmes de détection d'intrusion	Paris, France
2021	NeurIPS Meetup , Attaques adverses contre les systèmes de détection d'intrusion	Alger, Algérie
2018	OpenStack User Group Meeting , La sécurité dans OpenStack	Alger, Algérie
2017	Docker Chapter , Security Enhanced Linux	Alger, Algérie

ÉVALUATION PAR LES PAIRS

IEEE	Transactions on Intelligent Vehicles
Elsevier	Pattern Recognition
Elsevier	Computer Networks
Springer	International Journal of Information Security
ESORICS	European Symposium on Research in Computer Security
ISC	International Conference on Information Security
FPS	International Symposium on Foundations & Practice of Security
WPES	Workshop on Privacy in the Electronic Society
SECURITY	International Conference on Security and Cryptography
CSNet	Cyber Security in Networking Conference
CASCON	IEEE International Conference on Collaborative Advances in Software and Computing

MENTORAT

Doctorat	Mina Taraghi (diplômée en 2026) et Masoud Karami, Polytechnique Montréal.
Maîtrise	Maxime Gourceyraud (diplômé en 2024) et Joséphine Delas (diplômée en 2023), Polytechnique Montréal.
Premier cycle	Stagiaires de recherche Miran Qarachatani (Université Lakehead), Adjobi Vernet Emmanuel Placide (Université de Moncton), Junyu Huo (Université de l'Alberta) et Alfie Chuang (Université nationale de Taïwan).

COMMUNAUTÉ ET CONTRIBUTIONS SOCIALES

2026-...	Mentor , SPAR (Supervised Program for Alignment Research)	<i>En ligne</i>
2026	Comité de programme , Volet démonstrations d'outils, 17th International Conference on Internetworkware (Internetworkware 2026)	<i>Gold Coast, Australie</i>
2026	Comité de programme , Atelier CPRA, conjointement avec ARES 2026	<i>Linköping, Suède</i>
2025-...	Organisateur , Groupe de lecture en sécurité de l'IA de Mila	<i>Montréal, Canada</i>
2025	Coprésident , SEMLA Symposium 2025	<i>Montréal, Canada</i>
2025	Comité de programme , Atelier CPRA, conjointement avec ARES 2025	<i>Gand, Belgique</i>
2024-...	Membre , Comité de sécurité de l'information de Mila	<i>Montréal, Canada</i>
2024-...	Fondateur et organisateur , Groupe de lecture SEMLA	<i>Montréal, Canada</i>
2018-19	Président , Shellmates (premier club de cybersécurité en Algérie)	<i>Alger, Algérie</i>
2021-...	Délégué syndical , Association pour une Solidarité Syndicale à l'École Polytechnique (ASSEP)	<i>Montréal, Canada</i>
2023-...	Militant pour les droits des animaux , WeTheFree	<i>Montréal, Canada</i>
2020-21	Bénévole , Secours Populaire Français	<i>Rennes, France</i>
2021-24	Médiateur artistique , La Gang à Rambrou (centre communautaire dédié à la déficience intellectuelle et à l'autisme)	<i>Montréal, Canada</i>
2021-...	Comédien de théâtre , Les Pains Perdus	<i>Montréal, Canada</i>
2024-...	Choriste , Canopées	<i>Montréal, Canada</i>
2023-...	Guitariste , The Tiny Tax Band	<i>Montréal, Canada</i>

RÉFÉRENCES

Adam Oberman	Superviseur de postdoctorat, professeur titulaire à l'Université McGill et membre académique au Mila
Frédéric Cuppens	Directeur de recherche au doctorat, professeur titulaire à Polytechnique Montréal
Reda Yaich	Codirecteur de recherche au doctorat, directeur de l'équipe de cybersécurité à l'IRT SystemX
Foutse Khomh	Professeur titulaire à Polytechnique Montréal et membre académique au Mila
Yacine Challal	Directeur des études supérieures à l'ESI ex.INI
Fetheddine Guenaoui	Senior Manager chez KPMG

Coordonnées disponibles sur demande.