# Mohamed Amine Merzouk

Chercheur postdoctoral · Mila et Université McGill

mohamed-amine.merzouk@mila.quebec | mamerzouk.github.io | github.com/mamerzouk | linkedin.com/in/mamerzouk | Google Scholar

## Biographie

Chercheur en sécurité de l'IA, je travaille sur l'alignement des grands modèles de langage. Je suis chercheur postdoctoral à l'Université McGill et à Mila avec le Pr. Adam Oberman, où j'étudie des méthodes d'alignement qui agissent sur les représentations internes des modèles, ce que les modèles de langage encodent à propos de leur propre état et de leurs sorties, ainsi que l'honnêteté et la tromperie. Je viens de la cybersécurité : ma thèse de doctorat à Polytechnique Montréal, codirigée par le Pr. Frédéric Cuppens et Reda Yaich (IRT SystemX), portait sur les attaques adverses et les défenses pour la détection d'intrusion réseau fondée sur l'apprentissage automatique, et a été nommée pour le prix de la meilleure thèse.

## Éducation

**Philosophiæ doctor (PhD) en Génie Informatique** — *Montréal, Canada*

Polytechnique Montréal — *Janvier 2021 - Septembre 2024*

Thèse : *A Landscape of Adversarial Threats to Machine Learning-Based Intrusion Detection*, nommée pour le prix de la meilleure thèse. Direction : Pr. Frédéric Cuppens (Polytechnique Montréal) et Reda Yaich (IRT SystemX).

**Master en Informatique** — *Alger, Algérie*

École Nationale Supérieure d'Informatique (ESI ex.INI) — *Septembre 2018 - Septembre 2020*

Mémoire : *Adversarial Machine Learning against Anomaly-based Intrusion Detection Systems*. Direction : Pr. Lydia Bouzar.

**Ingénieur d'État en Informatique** — *Alger, Algérie*

École Nationale Supérieure d'Informatique (ESI ex.INI) — *Septembre 2017 - Septembre 2020*

**Classe préparatoire en Mathématiques et Informatique** — *Sidi Bel Abbès, Algérie*

École supérieure en informatique 08 Mai 1945 — *Septembre 2015 - Septembre 2017*

## Expérience professionnelle

**Chercheur postdoctoral** — *Montréal, Canada*

Université McGill et Mila - Institut Québécois d'Intelligence Artificielle — *Octobre 2024 - Présentement*

Sécurité de l'IA et alignement des grands modèles de langage, avec le Pr. Adam Oberman.

**Chargé de cours** — *Montréal, Canada*

Polytechnique Montréal — *Janvier 2021 - Août 2026*

Cours de cybersécurité au premier cycle et aux cycles supérieurs.

**Chercheur doctoral** — *Montréal, Canada*

IRT SystemX — *Janvier 2021 - Septembre 2024*

Recherche doctorale sur l'apprentissage automatique adverse pour la détection d'intrusion réseau.

**Chercheur stagiaire** — *Rennes, France*

IMT Atlantique — *Mars 2020 - Septembre 2020*

Stage de recherche ayant mené à l'article *A Deeper Analysis of Adversarial Examples in Intrusion Detection* (CRiSIS 2020).

**Auditeur stagiaire en cybersécurité** — *Alger, Algérie*

KPMG — *Juillet 2019 - Août 2019*

Mise en œuvre de la norme ISO 27001 de gestion de la sécurité de l'information : analyse des risques et rédaction de politiques et de mesures de sécurité.

**Ingénieur stagiaire en virtualisation et infonuagique** — *Alger, Algérie*

ADEX Technology — *Juin 2018 - Novembre 2018*

Conception et déploiement d' une infrastructure infonuagique privée Red Hat OpenStack : architecture des services de calcul et sécurisation de la plateforme.

**Technicien de support en TI** *Alger, Algérie*

British Petroleum *Septembre 2018 - Octobre 2018*

Soutien aux utilisateurs et maintenance des postes de travail : dépannage, installation de logiciels et gestion des comptes.

**Développeur logiciel stagiaire** *Alger, Algérie*

EGC 1988 *Juillet 2017 - Octobre 2017*

Développement d'un progiciel de gestion intégré (ERP).

## Expérience d'enseignement

| | |
|---|---|
| **INF8102** | **Sécurité dans les environnements infonuagiques.** Chargé de cours : Automne 2025. |
| **INF8085** | **Cybersécurité.** Chargé de cours : Été 2025, Hiver 2026, Été 2026. |
| **CR345** | **Sécurité des serveurs.** Chargé de cours : Hiver 2025. |
| **INF4420** | **Sécurité informatique.** Chargé de cours : Été 2023, Été 2024. Chargé de laboratoire : Hiver 2022, Automne 2022, Été 2023, Été 2024. |
| **INF6103** | **Cybersécurité des infrastructures critiques.** Chargé de laboratoire : Hiver 2022, Automne 2022, Automne 2023, Automne 2024. |
| **INF8602** | **Sécurité des systèmes d'exploitation.** Chargé de laboratoire : Hiver 2022. |
| **INF1040** | **Introduction à l'ingénierie informatique.** Correcteur : Hiver 2021, Automne 2021. |

## Publications

### Articles de revue

Efficiency vs. Alignment: Investigating Safety and Fairness Risks in Parameter-Efficient Fine-Tuning of LLMs
Mina Taraghi, Yann Pequignot, Amin Nikanjam, Mohamed Amine Merzouk, Foutse Khomh
*IEEE Transactions on Artificial Intelligence* (2026). 2026

Adversarial robustness of deep reinforcement learning-based intrusion detection
Mohamed Amine Merzouk, Christopher Neal, Joséphine Delas, Reda Yaich, Nora Boulahia-Cuppens, Frédéric Cuppens
*International Journal of Information Security* (2024). Springer, 2024

Investigating the practicality of adversarial evasion attacks on network intrusion detection
Mohamed Amine Merzouk, Frédéric Cuppens, Nora Boulahia-Cuppens, Reda Yaich
*Annals of Telecommunications* 77.11 (2022) pp. 763–775. Springer, 2022

### Articles de conférence

How Much is Left? LLMs Linearly Encode Their Remaining Output Length
Mohamed Amine Merzouk, Dmitri Carpov, Mirko Bronzi, Damiano Fornasiere, Adam Oberman
*Advances in Neural Information Processing Systems (NeurIPS)*, 2026

Efficient Safety Alignment of Language Models via Latent Personality Traits
Mohamed Amine Merzouk, Nolan Smyth, Damiano Fornasiere, Linh Le, David Williams-King, Adam Oberman
*Conference on Language Modeling (COLM)*, 2026

Latent Personality Alignment: Improving Harmlessness Without Mentioning Harms
Linh Le, David Williams-King, Mohamed Amine Merzouk, Aton Kamanda, Adam Oberman
*Trustworthy AI Workshop, International Conference on Learning Representations (ICLR)*, 2026

Diffusion-based Adversarial Purification for Intrusion Detection
Mohamed Amine Merzouk, Erwan Beurier, Reda Yaich, Nora Boulahia-Cuppens, Frédéric Cuppens, Foutse Khomh
*Proceedings of the 39th Annual IFIP WG 11.3 Conference on Data and Applications Security and Privacy (DBSec)*, 2025

Parameterizing poisoning attacks in federated learning-based intrusion detection
Mohamed Amine Merzouk, Frédéric Cuppens, Nora Boulahia-Cuppens, Reda Yaich
*Proceedings of the 18th International Conference on Availability, Reliability and Security (ARES)*, 2023

Evading Deep Reinforcement Learning-based Network Intrusion Detection with Adversarial Attacks
Mohamed Amine Merzouk, Joséphine Delas, Christopher Neal, Frédéric Cuppens, Nora Boulahia-Cuppens, Reda Yaich
*Proceedings of the 17th International Conference on Availability, Reliability and Security (ARES)*, 2022

A Deeper Analysis of Adversarial Examples in Intrusion Detection
Mohamed Amine Merzouk, Frédéric Cuppens, Nora Boulahia-Cuppens, Reda Yaich
*Proceedings of the 15th International Conference on Risks and Security of Internet and Systems (CRiSIS)*, 2021

### Prépublications

GrayShield: Bit-Level Sanitization for Transformer Model Supply-Chain Security
Armstrong Foundjem, Tsung-Hsien Chuang, Foutse Khomh, Mohamed Amine Merzouk
Preprint, arXiv:2610.04319, 2026

Quantifying Overclaiming Propensity in Frontier LLM Agents
Nolan Smyth, Yorguin-Jose Mantilla-Ramos, Pascal Jr Tikeng Notsawo, Saskia Helbling, Alberto Tosato, Mohamed Amine Merzouk, Nouha Dziri, Gauthier Gidel, Tommaso Tosato
Preprint, arXiv:2609.20812, 2026

Deep-Cover Agents: Long-Horizon Prompt Injections on Production LLM Systems
Neel Alex, Mohamed Amine Merzouk, David Krueger
Preprint, 2026

### Thèses et mémoires

A Landscape of Adversarial Threats to Machine Learning-Based Intrusion Detection
Mohamed Amine Merzouk
*Ph.D. Thesis. Polytechnique Montréal*, 2024

Adversarial Machine Learning against Anomaly-based Intrusion Detection Systems
Mohamed Amine Merzouk
*M.Sc. Thesis. École Nationale Supérieure d'Informatique (ESI ex. INI)*, 2020

## Prix et financement

| | | |
|---|---|---|
| 2025 | **Subvention AI Safety Catalyst (avec les Pr. Khomh, Ma et Goebel),** Canadian AI Safety Institute & CIFAR | *Montréal, Canada* |
| 2024 | **Nomination pour le prix de la meilleure thèse,** Polytechnique Montréal | *Montréal, Canada* |
| 2023 | **Prix de la meilleure présentation,** InCyber International Forum | *Montréal, Canada* |
| 2021 | **Bourse Mitacs Accélération Internationale pour la recherche doctorale,** Polytechnique Montréal | *Montréal, Canada* |
| 2014 | **1ère place aux Olympiades régionales de mathématiques,** ASA Science | *Alger, Algérie* |

## Conférences

| | | |
|---|---|---|
| 2025 | **IRT SystemX,** Purification adverse par diffusion pour la détection d'intrusion | *Paris, France* |
| 2023 | **InCyber International Forum,** L'IA de confiance (Prix de la meilleure présentation) | *Montréal, Canada* |
| 2023 | **BSides Algiers,** Menaces adverses pendant l'entraînement et l'inférence | *Alger, Algérie* |
| 2023 | **Cyberconference (Cybereco),** Table ronde sur la sécurité de l'IA | *Montréal, Canada* |
| 2022 | **School of AI Summit,** Empoisonnement adverses en apprentissage fédéré | *Alger, Algérie* |
| 2022 | **International Cybersecurity Forum,** Masterclass en apprentissage adverse | *Montréal, Canada* |
| 2022 | **Canadian AI Federated Learning Workshop,** La menace des clients malveillants en apprentissage fédéré | *Toronto, Canada* |
| 2022 | **Mila - Institut Québecois d'Intelligence Artificielle,** Génération d'exemples adverses avec contraintes | *Montréal, Canada* |
| 2021 | **Lancement de la chaire CRITiCAL,** Attaques adverses contre les systèmes de détection d'intrusion | *Paris, France* |
| 2021 | **NeurIPS Meetup,** Attaques adverses contre les systèmes de détection d'intrusion | *Alger, Algérie* |
| 2018 | **OpenStack User Group Meeting,** La sécurité dans OpenStack | *Alger, Algérie* |
| 2017 | **Docker Chapter,** Security Enhanced Linux | *Alger, Algérie* |

## Évaluation par les pairs

| | |
|---|---|
| **IEEE** | Transactions on Intelligent Vehicles |
| **Elsevier** | Pattern Recognition |
| **Elsevier** | Computer Networks |
| **Springer** | International Journal of Information Security |
| **ESORICS** | European Symposium on Research in Computer Security |
| **ISC** | International Conference on Information Security |
| **FPS** | International Symposium on Foundations & Practice of Security |
| **WPES** | Workshop on Privacy in the Electronic Society |
| **SECRYPT** | International Conference on Security and Cryptography |
| **CSNet** | Cyber Security in Networking Conference |
| **CASCON** | IEEE International Conference on Collaborative Advances in Software and Computing |

## Mentorat

| | |
|---|---|
| **Doctorat** | Mina Taraghi (diplômée en 2026) et Masoud Karami, Polytechnique Montréal. |
| **Maîtrise** | Maxime Gourceyraud (diplômé en 2024) et Joséphine Delas (diplômée en 2023), Polytechnique Montréal. |
| **Premier cycle** | Stagiaires de recherche Miran Qarachatani (Université Lakehead), Adjobi Vernet Emmanuel Placide (Université de Moncton), Junyu Huo (Université de l'Alberta) et Alfie Chuang (Université nationale de Taïwan). |

## Communauté et contributions sociales

| | | |
|---|---|---|
| 2026-... | **Mentor,** SPAR (Supervised Program for Alignment Research) | *En ligne* |
| 2026 | **Comité de programme,** Volet démonstrations d'outils, 17th International Conference on Internetware (Internetware 2026) | *Gold Coast, Australie* |
| 2026 | **Comité de programme,** Atelier CPRA, conjointement avec ARES 2026 | *Linköping, Suède* |
| 2025-... | **Organisateur,** Groupe de lecture en sécurité de l'IA de Mila | *Montréal, Canada* |
| 2025 | **Coprésident,** SEMLA Symposium 2025 | *Montréal, Canada* |
| 2025 | **Comité de programme,** Atelier CPRA, conjointement avec ARES 2025 | *Gand, Belgique* |
| 2024-... | **Membre,** Comité de sécurité de l'information de Mila | *Montréal, Canada* |
| 2024-... | **Fondateur et organisateur,** Groupe de lecture SEMLA | *Montréal, Canada* |
| 2018-19 | **Président,** Shellmates (premier club de cybersécurité en Algérie) | *Alger, Algérie* |
| 2021-... | **Délégué syndical,** Association pour une Solidarité Syndicale à l'École Polytechnique (ASSEP) | *Montréal, Canada* |
| 2023-... | **Militant pour les droits des animaux,** WeTheFree | *Montréal, Canada* |
| 2020-21 | **Bénévole,** Secours Populaire Français | *Rennes, France* |
| 2021-24 | **Médiateur artistique,** La Gang à Rambrou (centre communautaire dédié à la déficience intellectuelle et à l'autisme) | *Montréal, Canada* |
| 2021-... | **Comédien de théâtre,** Les Pains Perdus | *Montréal, Canada* |
| 2024-... | **Choriste,** Canopées | *Montréal, Canada* |
| 2023-... | **Guitariste,** The Tiny Tax Band | *Montréal, Canada* |

## Références

| | |
|---|---|
| **Adam Oberman** | Superviseur de postdoctorat, professeur titulaire à l'Université McGill et membre académique au Mila |
| **Frédéric Cuppens** | Directeur de recherche au doctorat, professeur titulaire à Polytechnique Montréal |
| **Reda Yaich** | Codirecteur de recherche au doctorat, directeur de l'équipe de cybersécurité à l'IRT SystemX |
| **Foutse Khomh** | Professeur titulaire à Polytechnique Montréal et membre académique au Mila |
| **Yacine Challal** | Directeur des études supérieures à l'ESI ex.INI |
| **Fetheddine Guenaoui** | Senior Manager chez KPMG |

Coordonnées disponibles sur demande.